BÁO CÁO TIẾN ĐỘ PROJECT

German Credit Risk Prediction

Phân loại rủi ro tín dụng theo chi phí sai lầm

Nguyễn Hữu Anh / Cao Hà Hải Đăng
Trần Gia Nam

Báo cáo tiến độ • 09/10/2026

Project introduction

Bài toán: một hồ sơ tín dụng thuộc lớp Good hay Bad?

- Dữ liệu đầu vào: thông tin khoản vay, tài khoản, lịch sử tín dụng và đặc điểm người vay.
- Dữ liệu cung cấp: **800 hồ sơ có nhãn**, **200 hồ sơ competition không có nhãn công khai**; **20 biến đầu vào** ban đầu.
- Đầu ra: điểm $P(\mathrm{Bad})$, sau đó áp dụng ngưỡng để phân loại.

$$P(\mathrm{Bad}) \geq t \Rightarrow \mathrm{Bad}\ (1) \qquad P(\mathrm{Bad}) < t \Rightarrow \mathrm{Good}\ (0)$$

Phạm vi báo cáo: chuẩn bị dữ liệu, thiết kế CV và setup model.

Nguồn: `main_v2.ipynb`, phần 1–3; dữ liệu trong `data_raw`.

Mục tiêu của nhóm và cách chấm trên Kaggle

Mục tiêu của nhóm

$$\text{Cost} = 5 \times FN + FP$$

FN: hồ sơ Bad bị dự đoán Good.

FP: hồ sơ Good bị dự đoán Bad.

Bỏ sót một hồ sơ Bad bị phạt **gấp 5 lần** cảnh báo nhầm một hồ sơ Good.

Đánh giá trên Kaggle

- Chấm dự đoán trên tập competition theo **metric của cuộc thi**.
- Nhóm dùng **Cost trong CV** để lựa chọn cấu hình và threshold.
- Accuracy, Recall và AUC là các chỉ số theo dõi bổ sung.

Hướng làm: chấp nhận thêm FP nếu giảm được nhiều FN có chi phí cao.

Nguồn: Notebook, phần 1 và 10; README, mục 2 và 12. Metric Kaggle chưa được xác minh trong nguồn cung cấp.

Checklist công việc trong phạm vi báo cáo

Công việc	Đầu ra đã có trong repo
Xác định target và mục tiêu chi phí	Bad = 1; Cost = $5FN + FP$
Kiểm tra dữ liệu và thực hiện EDA	Cấu trúc, tỷ lệ lớp, phân bố biến
Tách các tập dữ liệu	Development / benchmark / competition
Setup preprocessing pipeline	Xử lý biến số và biến phân loại
Thiết lập folds CV dùng chung	5 Outer folds; 3 Inner folds
Setup các model và preset	9 họ model; 37 cấu hình

Mốc báo cáo: đã có thiết kế và setup thí nghiệm để so sánh các model.

Nguồn: Notebook, phần 1–9; `data_splits_colab`; các module trong `models`.

Cách chia và sử dụng dữ liệu

Tập dữ liệu	Good	Bad	Tổng	Vai trò
Development	480	160	**640**	Phát triển; CV; chọn rule
Historical benchmark	120	40	**160**	Kiểm tra sau khi chọn rule
Competition	Không có nhãn		**200**	Dự đoán; tạo submission

- Chia **800 hồ sơ có nhãn** theo stratified split; giữ tỷ lệ Good/Bad là **75% / 25%**.
- **Development** dùng cho EDA và CV; benchmark giữ riêng khỏi quá trình lựa chọn.
- Lưu **danh sách IDs và folds** để mọi thành viên dùng cùng cách chia.

Nguồn: Các CSV trong `data_splits_colab/data_split`; notebook, phần 2–3 và 7.

Setup preprocessing dùng chung cho các model

3 biến số

`duration`, `amount`, `age`

Median imputation

↓

StandardScaler

17 biến phân loại

Mã số được xem là categorical.

Most-frequent imputation

↓

OneHotEncoder

`handle_unknown="ignore"`

ColumnTransformer + model được ghép trong một Pipeline

- `Id` và target được loại khỏi predictors; setup ban đầu giữ **20 biến**.
- Chỉ training fold được **fit**; validation chỉ **transform và predict**.

Nguồn: Notebook, phần 5–6; các model builders trong `models`.

Nested CV: Inner chọn, Outer đánh giá

5 Outer folds trên 640 hồ sơ; 3 Inner folds trong mỗi Outer Training

Tầng CV	Training	Validation	Vai trò
Outer (mỗi vòng)	**512**	**128**	Đánh giá quy trình lựa chọn
Inner (trong 512)	341–342	170–171	Chọn model, preset, threshold

1. Tạo dự đoán **OOF** từ 3 Inner folds; chọn cấu hình và threshold có Cost nhỏ nhất.
2. Fit lại cấu hình thắng trên 512 hồ sơ; đánh giá trên 128 hồ sơ Outer Validation.
3. Lặp đủ 5 Outer folds; gộp dự đoán để đánh giá toàn bộ quy trình.

Stratified CV; random state = 42; mọi model dùng cùng fold IDs.

Nguồn: Notebook, phần 6–7 và 10–12: quy trình CV đã thiết lập.

Các model và preset được khảo sát

8 thuật toán + 1 Dummy baseline = 9 họ model, 37 cấu hình

Model	Hyperparameter grid	Số preset
Dummy	Baseline	1
Logistic Regression	$C \in \{0.1, 1, 10\}$; class weight: None / balanced	6
Gaussian Naive Bayes	var smoothing: 10^{-9} / 10^{-3}	2
KNN	$k \in \{5, 15, 31\}$; weights: uniform / distance	6
Decision Tree	depth: 3 / 6; min leaf: 5 / 15	4
Random Forest	depth: 5 / None; min leaf: 3 / 10	4
Extra Trees	depth: 5 / None; min leaf: 3 / 10	4
RBF SVM	$C \in \{0.1, 1, 10\}$; gamma: scale / 0.01	6
Gradient Boosting	learning rate: 0.05 / 0.1; depth: 1 / 2	4

Mỗi preset dùng cùng Pipeline và folds; threshold được chọn bằng Inner OOF.

Nguồn: Notebook, phần 9: `model_candidates`; các module trong `models`.